

Машинное обучение

Лекция 5

Логистическая регрессия и SVM

Евгений Егоров

https://github.com/WeaselCMC/ml_dpo_2021

План лекции

- Бинарная классификация
- Предсказание вероятностей
- Логистическая регрессия
- Метод опорных векторов

Линейная классификация

- Решаем задачу бинарной классификации:

$$\mathbb{Y} = \{-1, +1\}$$


- Линейная модель:

$$a(x) = \text{sign}(\langle w, x \rangle - t) = \text{sign}(\langle w, x \rangle)$$


- Функция потерь:

$$Q(w, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [y_i \underbrace{\langle w, x_i \rangle}_{M_i} < 0]$$


$M_i = \text{"отстгн"}$



Линейная классификация




Линейная классификация



Линейная классификация



$$0 \leq \frac{1}{\ell} \sum_{i=1}^{\ell} [y_i \langle w, x_i \rangle < 0] \leq \frac{1}{\ell} \sum_{i=1}^{\ell} \tilde{L}(y_i \langle w, x_i \rangle) \rightarrow \min_w$$



Линейная классификация


- Разные верхние оценки => разные модели

- Свойства модели => верхняя оценка



$$f(100 \operatorname{sign}\{\langle w, x \rangle\}) \in \{0,1\} ?$$

Предсказание вероятностей



Предсказание вероятностей


- Кредитный скоринг
- Стратегия: выдавать кредит только клиентам с вероятностью возврата > 0.9 *← не вероятно, что это число*
- 10% невозвращенных кредитов - нормально

$$\underbrace{10^6 \cdot 0.1}$$

Предсказание вероятностей

- Реклама в интернете:
 - $b(x)$ — вероятность клика
 - $c(x)$ — прибыль в случае клика
 - $\underbrace{c(x)b(x)}$ — хотим оптимизировать ?


Предсказание вероятностей



$$\frac{1}{1 + \exp(-\theta)} \stackrel{d(\cdot)}{\sim}$$

\Rightarrow 1) $\{0, 1\} \sim (?)$
 2) Входной
 матрица считать
 вероятностной

Логистическая регрессия



Логистическая регрессия

- Решаем задачу бинарной классификации:


$$\mathbb{Y} = \{-1, +1\}$$

- Линейная модель:

$$a(x) = \text{sign}(b(x)) = \text{sign}(\langle w, x \rangle)$$

- Может использовать $b(x)=\langle w, x \rangle$ как оценку вероятности? \checkmark

Логистическая регрессия



Логистическая регрессия

- Давайте переведем выход модели на отрезок [0, 1] ✓


- Например, с помощью сигмоиды

$w \in \mathbb{R}^k$
 $x \in \mathbb{R}^k$
 $\sigma \rightarrow$ веса
 \rightarrow объект

$$\sigma(w^T x) = \frac{1}{1 + \exp(-w^T x)}$$


↑
x
y¹

Сигмоида



Предсказание вероятностей

1. $\log \mathcal{G}$ ~~всегда~~
2. $+ \|w\|^2$
- 3.



Логистическая регрессия

- Задача бинарной классификации: $\mathbb{Y} = \{-1, +1\}$
- Предсказание вероятностей

$$P(y_i=1) = \sigma(\langle w, x_i \rangle)$$

Теперь мы можем использовать метод максимального правдоподобия

Логистическая регрессия

$$y_n \in \{-1, +1\} \quad \{(x_n, y_n)\}_{n=1}^N$$

$$\prod_{n=1}^{N_1} P_w(y_n = 1 | x_n) \prod_{n=1}^{N_2} P_w(y_n = -1 | x_n) \rightarrow \max_w$$

(Влияние на w)

\Rightarrow сумма

$$\max \sum_{n=1}^N \log \hat{C}(y_n < w, x_n)$$

$$\hat{C} = \frac{1}{1 + \exp(y_n < w, x_n)}$$

$$P_w : \sum_{n=1}^N \frac{1 - \exp(y_n < w, x_n)}{1 + \exp(y_n < w, x_n)} y_n x_n$$

$$\begin{aligned} & \left(\frac{1 - \hat{C}}{\hat{C}} (y_n < w, x_n) \right) y_n x_n \\ & (y_n - E y(x_n)) x_n \end{aligned}$$

$E y(x_n) = \boxed{E y(\hat{x})} x_n$

Логистическая регрессия

$$-\sum_{i=1}^{\ell} \{ [y_i = 1] \log \sigma(\langle w, x_i \rangle) + [y_i = -1] \log(1 - \sigma(\langle w, x_i \rangle)) \} =$$

$$-\sum_{i=1}^{\ell} \left\{ [y_i = 1] \log \frac{1}{1 + \exp(-\langle w, x \rangle)} + [y_i = -1] \log \left(1 - \frac{1}{1 + \exp(-\langle w, x \rangle)}\right) \right\} =$$

$$-\sum_{i=1}^{\ell} \left\{ [y_i = 1] \log \frac{1}{1 + \exp(-\langle w, x \rangle)} + [y_i = -1] \log \left(\frac{1}{1 + \exp(\langle w, x \rangle)}\right) \right\} =$$

$$\sum_{i=1}^{\ell} \{ [y_i = 1] \log(1 + \exp(-\langle w, x \rangle)) + [y_i = -1] \log(1 + \exp(\langle w, x \rangle)) \} =$$

$$\sum_{i=1}^{\ell} \log(1 + \exp(-y_i \langle w, x_i \rangle))$$

Логистическая регрессия

- Немало задач, где нужно предсказывать вероятности
- Можно применить сигмоиду к линейной модели, чтобы получать числа от 0 до 1
- Логистическая функция максимизирует отступы — то есть приближает вероятности к 1 или 0 в зависимости от класса

1.

ЕКОДУ

 $\in \mathbb{R}$? IN+

GLM Pet.

Логистическая регрессия и друзья

2. MLE
 $\hat{\theta}(\langle w, x_n \rangle)$

$$\triangleright: (y_n - \underbrace{|E y|}_{\text{Это модель}}(x_n)) x_n \checkmark ?$$

$$\stackrel{MLE}{\rightarrow} \log P(Y_n) = \frac{\mu^{y_n}}{y_n!} \exp(-\mu) \quad \log P(Y_n) = y_n \cdot \cancel{\log \mu} - \mu$$


$$\Theta = \log \mu, \mu = \exp(\Theta) \quad y_n \cdot \Theta - \exp(\Theta)$$

$$\sum \log P(Y_n | X_n) = \sum y_n \cdot \cancel{\langle w, x_n \rangle} - \exp(\cancel{\langle w, x_n \rangle})$$


$$\sum_{n=1}^N (y_n \cdot x_n - \exp(\cancel{\langle w, x_n \rangle}) \cdot \cancel{x_n} x_n) \quad \Sigma.$$

μ.O.

1. Окей
 но как
 решить?



Какой классификатор лучше?




Отступ классификатора

Вспомним, что линейный классификатор задает гиперплоскость $\langle w, x \rangle = 0$.




Расстояние от любой точки x до этой гиперплоскости —




Отступ классификатора — расстояние от гиперплоскости до ближайшего объекта


Какой классификатор лучше?



Какой классификатор лучше? имеет больший отступ?



Какой классификатор лучше? имеет больший отступ?




Отступ классификатора


- Будем максимизировать отступ классификатора — расстояние от гиперплоскости до ближайшего объекта
- При этом будет стараться сделать поменьше ошибок
- По сути, делаем как можно меньше предположений о модели, и верим, что это снизит вероятность переобучения

Простой случай

- Будем считать, что выборка линейно разделима
- Существует линейный классификатор, не допускающий ни одной ошибки




Линейно разделимый случай



Линейно разделимый случай

Требование 1: максимальный отступ

$$\min_i \frac{|\langle w, x_i \rangle|}{\|w\|}$$



Требование 2: Нет ошибок

$$\underbrace{y_i \langle w, x_i \rangle}_{\{-1, 1\}} > 0, i = 1 \dots N$$

Небольшое предположение

Линейный классификатор:

$$a(x_i) = \text{sign}(\langle w, x_i \rangle)$$

Если мы поделим w на число $\underbrace{a > 0}$, то выходы классификатора никак не поменяются:

$$a(x_i) = \text{sign} \left(\frac{\langle w, x_i \rangle}{\overbrace{a}} \right) = \text{sign} (\langle w, x_i \rangle)$$

Небольшое предположение

Если мы поделим w на число $a > 0$, то выходы классификатора никак не поменяются:

$$a(x_i) = \text{sign} \left(\frac{\langle w, x_i \rangle}{a} \right) = \text{sign} (\langle w, x_i \rangle)$$

Давайте поделим на

$$\min_i |\langle w, x_i \rangle|$$

$$\tilde{w} = \frac{w}{\min_i |\langle w, x_i \rangle|}$$

$$\min_i |\langle w, x_i \rangle| = 1$$

Небольшое предположение

Давайте поделим на $\min_i |\langle w, x_i \rangle|$

$$\min_i |\langle \tilde{w}, x_i \rangle| = 1$$

Отступ классификатора:

$$\min_i \frac{|\langle \tilde{w}, x_i \rangle|}{\|\tilde{w}\|} = \frac{\min_i |\langle \tilde{w}, x_i \rangle|}{\|\tilde{w}\|} = \frac{1}{\|\tilde{w}\|}$$

Линейно разделимый случай

Требование 1: максимальный отступ

$$\frac{1}{\|w\|} \rightarrow \max_w \quad \checkmark$$

Требование 2: Нет ошибок

$$y_i \langle w, x_i \rangle > 0, i = 1 \dots l \quad \checkmark$$

Требование 3:

Линейно разделимый случай

Требование 1: максимальный отступ

$$\frac{1}{\|w\|} \rightarrow \max_w$$

Требование 2: Нет ошибок

$$y_i \langle w, x_i \rangle > 0, i = 1 \dots l$$

Требование 3:

$$\sqrt{\min_i |\langle w, x_i \rangle|} = 1$$

Линейно разделимый случай

Требование 1: максимальный отступ

$$\frac{1}{\|w\|} \rightarrow \max_w$$

Требование 2: Нет ошибок

$$y_i \langle w, x_i \rangle > 0, i = 1 \dots N$$

Требование 3:

$$|\langle w, x_i \rangle| \geq 1, \quad i = 1 \dots N$$

Линейно разделимый случай

Требование 1: максимальный отступ

$$\frac{1}{\|w\|} \rightarrow \max_w$$

Требование 2: $y_i \langle w, x_i \rangle > 0, i = 1 \dots l$

Требование 3: $|\langle w, x_i \rangle| \geq 1, i = 1 \dots l$

Требование 2 + 3:

Линейно разделимый случай

Требование 1: максимальный отступ

$$\frac{1}{\|w\|} \rightarrow \max_w$$

Требование 2: $y_i \langle w, x_i \rangle > 0, i = 1 \dots N$

+
Требование 3: $|\langle w, x_i \rangle| \geq 1, i = 1 \dots N$

Требование 2 + 3:

$$\underbrace{\sqrt{y_i \langle w, x_i \rangle} \geq 1, i = 1 \dots N}$$

Линейно разделимый случай

Требование 1: максимальный отступ


$$\frac{1}{\|w\|} \rightarrow \max_{\circlearrowleft w}$$

Требование 2 + 3: $y_i \langle w, x_i \rangle \geq 1, \quad i = 1 \dots l$

Итого:

$$\begin{cases} \min_w \|w\| \\ y_i \langle w, x_i \rangle \geq 1 - \xi_i \end{cases}$$

Линейно неразделимый случай



Линейно неразделимый случай

- Любой линейный классификатор допускает хотя бы одну ошибку

$$\begin{cases} \min_w \|w\| \\ y_i \langle w, x_i \rangle \geq 1 \end{cases}$$


- Давайте смягчим условия

$$\begin{cases} \min_w \|w\| \\ y_i \langle w, x_i \rangle \geq 1 - \xi_i \\ \xi_i \geq 0 \end{cases}$$

\Rightarrow *релаксация на допустимых ошибках.*


Линейно неразделимый случай

$$\left\{ \begin{array}{l} \min_w \left[\|w\| + \sum_i \xi_i \right] \\ y_i \langle w, x_i \rangle \geq 1 - \xi_i \\ \xi_i \geq 0 \end{array} \right.$$



Линейно неразделимый случай

$$\begin{cases} \min_w \|w\| \\ y_i \langle w, x_i \rangle \geq 1 - \xi_i \\ \xi_i \geq 0 \end{cases}$$



$\xi_i = 100000000$

Линейно неразделимый случай

$i = 1, \dots, N$

число объектов
6 векторов
cvx opt

V.

очищая модель

регу.

$$\min_w \|Y - Xw\|_2^2 + \lambda \|w\|_2^2$$

$$\min_w \sum_i \xi_i + \frac{1}{C} \|w\|_2^2$$


C =

$$\begin{cases} \min_w \|w\| \\ y_i \langle w, x_i \rangle \geq 1 - \xi_i \\ \xi_i \geq 0 \end{cases}$$



коэффициент
регул.


polytyle



$$\begin{cases} \min_{w, \xi} \|w\|_2^2 + C \sum_i \xi_i \\ y_i \langle w, x_i \rangle \geq 1 - \xi_i \\ \xi_i \geq 0 \end{cases}$$


1. инициализация
2. ошибка габаритная

Линейно неразделимый случай



Маленькое С

Линейно неразделимый случай



Метод опорных векторов

$$\begin{cases} \min_{w,\xi} \|w\| + C \sum_i \xi_i \\ y_i \langle w, x_i \rangle \geq 1 - \xi_i \\ \xi_i \geq 0 \end{cases}$$

Объединим ограничения

$$\xi_i \geq \max(0, 1 - y_i \langle w, x_i \rangle)$$

Итоговая задача оптимизации

$$\min_w \left(\|w\| + C \sum_i \max(0, 1 - y_i \langle w, x_i \rangle) \right)$$

Метод опорных векторов


Итоговая задача оптимизации

$$\min_w \left(\|w\| + C \sum_i \max(0, 1 - y_i \langle w, x_i \rangle) \right)$$

Hingle Loss (верхняя оценка) + L2 регуляризация


$$\min_w \left(\sum_i \max(0, 1 - y_i \langle w, x_i \rangle) + \lambda \|w\| \right)$$

Сравнение логистической регрессии и SVM




Итого

- Метод опорных векторов основан на идее максимизации отступа классификатора
- В линейно неразделимом случае мы должны выбрать, что важнее, — ширина зазора или число ошибок
- По сути, SVM — это определённая функция потерь и регуляризация

- ① SVM = $(\langle x_i, w \rangle) + \lambda \|w\|_2^2$
- ↑
numer. per.
- up local
gradient.
- ② Decision boundary
 ↓
 kernel ↓ weight:
- ③ $\langle x_i, x_j \rangle = \sum_n x_i^n x_j^n$
- $\langle x_i, x_j \rangle$
- RBF:
 $\langle x_i, x_j \rangle = \exp(-\|x_i - x_j\|^2)$
- ④ SVM kernel = 'rbf' $y_s = \sum_{n=1}^N K(x_s, x_n) \cdot y_n$
- 'poly' $x_i x_j$ $x_i^2 x_j^2$ $x_i x_j^2$
- 

нужные с неподвижностью



$$\begin{cases} \cos(\varphi + 2\pi) \\ \sin(\varphi + 2\pi) \end{cases}$$

$$\sqrt{\cos^2(\frac{\varphi}{T})}$$

V. Mealy
нужны

Время вспомогательное
 $\underline{2\pi T}$ дел

+S


песня: 12012-05-1: 8, AM' \rightarrow

date.time

$\frac{8}{12}$

$\frac{1}{6}$

$\frac{1}{4}$



Нулем